

LABORATORIO I - DISTRIBUCIONES PARAMÉTRICAS

Detective de Distribuciones en el Censo de Ingresos: Explorando las Características Socioeconómicas

Objetivo General: Los estudiantes deben analizar las distribuciones paramétricas de las variables en el Census Income Dataset para comprender las características socioeconómicas y preparar los datos para tareas de modelado predictivo.

Objetivos Específicos:

- Clasificar las columnas del Census Income Dataset como discretas o continuas.
- Seleccionar las variables continuas relevantes del Census Income Dataset.
- Utilizar histogramas y gráficos de densidad para visualizar la forma de la distribución de las variables continuas (age, fnlwgt, education-num, capital-gain, capital-loss, hours-per-week).
- Generar gráficos Cuantil-Cuantil (Q-Q plots) para comparar las distribuciones de las variables continuas con la distribución normal.
- Aplicar la prueba de Shapiro-Wilk para evaluar formalmente la normalidad de las variables continuas.
- Interpretar las visualizaciones y los resultados de la prueba de Shapiro-Wilk para determinar si las variables continuas se aproximan a una distribución normal.
- Discutir las posibles razones de las desviaciones de la normalidad observadas.
- Documentar el proceso de análisis y las conclusiones sobre las distribuciones de las variables continuas.

Materiales:

Conjunto de Datos: Census Income Dataset (Adult dataset). Los estudiantes deben trabajar con las columnas relevantes mencionadas en los objetivos.

Software Estadístico o Herramientas de Programación: A elección de los estudiantes.

Plantilla para el Informe:

Procedimiento:

1. Introducción: Breve explicación del objetivo

2. Carga y Selección de Datos:

- Cargar el Census Income Dataset en la herramienta elegida.
- Seleccionar todas las columnas del dataset para la clasificación inicial.
- Seleccionar las columnas correspondientes a las variables continuas para el análisis del punto 7.

3. Clasificación del Tipo de Variable:

- Para cada columna del dataset, determinar si es discreta o continua.
- Proporcionar una breve justificación para cada clasificación.

4. Exploración Inicial de las Variables Continuas:

- Calcular estadísticas descriptivas básicas (media, mediana, desviación estándar, asimetría, curtosis) para cada variable continua.

5. Visualización de la Distribución:

- Para cada variable continua, crear histogramas y gráficos de densidad.
- Analizar la forma de las distribuciones (simetría, asimetría, número de picos).

6. Evaluación de Normalidad con Gráficos Q-Q:

- Para cada variable continua, generar gráficos Q-Q comparando su distribución con la distribución normal.
- Evaluar visualmente qué tan cerca se ajustan los datos a la línea de referencia.

7. Prueba de Shapiro-Wilk para Normalidad:

- Aplicar la prueba de Shapiro-Wilk a cada variable continua para evaluar formalmente la normalidad.
- Interpretar el valor p de cada prueba

8. Análisis y Discusión:

- Basándose en las visualizaciones y los resultados de la prueba de Shapiro-Wilk, determinar si cada variable continua se aproxima a una distribución normal.
- Discutir las posibles razones de las desviaciones de la normalidad observadas en algunas variables.

9. Documentación:

- Documentar el proceso seguido para cada variable.
- Incluir la clasificación de las variables y sus justificaciones.
- Incluir las visualizaciones generadas.
- Reportar los resultados de la prueba de Shapiro-Wilk.
- Presentar las conclusiones sobre la normalidad de cada variable continua y la discusión de las posibles razones.

10. Preguntas Guía para el Informe/Discusión:

- ¿Cómo clasificaste cada una de las columnas del dataset (discreta o continua)? Justifica brevemente tus clasificaciones.
- Para cada variable continua, ¿cómo describe la forma del histograma y el gráfico de densidad su distribución? ¿Sugiere una distribución normal?
- ¿Cómo se ven los gráficos Q-Q para cada variable continua en comparación con la distribución normal? ¿Qué variables parecen ajustarse mejor?
- ¿Cuáles fueron los valores p de la prueba de Shapiro-Wilk para cada variable continua? ¿Qué conclusiones puedes extraer sobre la normalidad de cada una?
- ¿Qué variables continuas parecen desviarse significativamente de una distribución normal? ¿Puedes proponer posibles razones para estas desviaciones basadas en tu conocimiento del dataset y las variables?

Rúbrica de Evaluación (Total: 36 puntos)

Criterio	Excelente (4 puntos)	Bueno (3 puntos)	Regular (2 puntos)	Deficiente (1 punto)
Clasificación del tipo de variable	Clasifica correctamente todas las columnas del dataset como discretas o continuas, con justificaciones precisas y completas.	Clasifica correctamente la mayoría de las columnas, con justificaciones adecuadas. Puede haber alguna confusión menor en casos ambiguos.	Clasifica correctamente algunas columnas, pero muestra confusión o errores en la clasificación de varias variables. Las justificaciones son limitadas o imprecisas.	Clasifica incorrectamente la mayoría de las columnas o no proporciona justificaciones para sus clasificaciones.
Selección y carga de datos	Carga correctamente el dataset y selecciona todas las variables continuas relevantes sin errores.	Carga el dataset y selecciona la mayoría de las variables continuas relevantes con errores mínimos.	Carga el dataset con dificultad o omite varias variables continuas relevantes.	No puede cargar el dataset o no selecciona las variables continuas relevantes.
Visualización de las distribuciones continuas	Genera histogramas y gráficos de densidad claros y apropiados para todas las variables continuas. Describe correctamente la forma de cada distribución.	Genera visualizaciones apropiadas para la mayoría de las variables continuas y describe generalmente bien sus formas.	Genera algunas visualizaciones, pero pueden ser poco claras o inapropiadas. La descripción de las formas es limitada o incorrecta.	No genera visualizaciones o las generadas son completamente inapropiadas. No describe las formas de las distribuciones.
Evaluación de normalidad con gráficos Q-Q	Genera gráficos Q-Q para todas las variables continuas contra la distribución normal y los interpreta	Genera gráficos Q-Q para la mayoría de las variables continuas y los interpreta	Genera algunos gráficos Q-Q, pero la interpretación es superficial o incorrecta. No	No genera gráficos Q-Q o la interpretación es

	correctamente para evaluar el ajuste visual. Identifica claramente las variables que se desvían de la normalidad en los gráficos.	generalmente bien. Identifica las desviaciones de la normalidad en la mayoría de los casos.	identifica claramente las desviaciones de la normalidad.	completamente errónea.
Aplicación e interpretación de la prueba de Shapiro-Wilk	Aplica correctamente la prueba de Shapiro-Wilk a todas las variables continuas e interpreta el valor p para determinar si se rechaza o no la hipótesis nula de normalidad.	Aplica generalmente la prueba correctamente e interpreta el valor p para la mayoría de las variables continuas.	Aplica la prueba con errores o la interpretación del valor p es inconsistente o incorrecta para varias variables.	No aplica la prueba de Shapiro-Wilk o la interpretación es completamente errónea.
Análisis y discusión de las distribuciones	Realiza un análisis perspicaz de las distribuciones de las variables continuas, integrando las visualizaciones y los resultados de la prueba de Shapiro-Wilk. Ofrece explicaciones razonables y bien fundamentadas para las desviaciones de la normalidad.	Realiza un análisis adecuado de las distribuciones, mencionando las visualizaciones y los resultados de la prueba. Ofrece algunas explicaciones para las desviaciones de la normalidad.	El análisis es superficial o se basa principalmente en una sola fuente de evidencia. Las explicaciones para las desviaciones de la normalidad son limitadas o poco claras.	El análisis es incompleto o incorrecto. No ofrece explicaciones para las desviaciones de la normalidad.
Documentación y claridad del informe	El informe es claro, conciso, bien organizado y presenta todas las visualizaciones, resultados y análisis de manera lógica y fácil de entender.	El informe es generalmente claro y organizado, presentando la mayoría de los elementos requeridos.	El informe es desorganizado, falta claridad o no incluye todos los elementos requeridos (clasificación, visualizaciones, resultados, análisis).	El informe es confuso, incompleto y difícil de entender.

Uso adecuado de herramientas	Utiliza el software estadístico o las herramientas de programación de manera eficiente y correcta para realizar todas las tareas requeridas (clasificación, visualizaciones, estadísticas, prueba de normalidad).	Utiliza generalmente las herramientas de manera adecuada, aunque puede haber algunas ineficiencias o errores menores.	Muestra dificultades significativas en el uso de las herramientas, lo que afecta la realización de algunas tareas.	No utiliza las herramientas de manera efectiva o no puede realizar las tareas requeridas.
Reflexión y comprensión conceptual	Demuestra una comprensión profunda de los conceptos de tipos de variables, distribuciones paramétricas (específicamente la normal), visualización de datos y pruebas de normalidad en la justificación de sus observaciones y en las respuestas a las preguntas guía.	Demuestra una buena comprensión de los conceptos en la mayoría de los casos.		